

数据挖掘与机器学习

潘斌

panbin@nankai.edu.cn

范孙楼227

1

上节回顾

- 图像特征提取
 - 灰度共生矩
 - 局部二值模式LBP
- 感知准则
 - $a^T y_i > 0$ ——正确分类
 - $a^T y_i < 0$ ——错误分类
 - 梯度下降求解
- 最小错分、最小平方误差准则
- 贝叶斯派和频率派

贝叶斯公式

$$P(\theta|X) = \frac{P(X|\theta) \times P(\theta)}{P(X)}$$

$$P(B_i|A) = \frac{P(B_i) P(A|B_i)}{\sum_{j=1}^n P(B_j) P(A|B_j)}$$

4.1 基本概念

● Bayes分类器设计思路

- 寻求概率意义上的最小错误率的分类器
- 即具有最小错分概率的分类器——分类器设计的最优解

4.2.1 问题 (P代表概率, p代表概率密度函数)

- **Bayes**决策已知条件和问题 (先考虑**C = 2**分类问题)
 - 两类问题: ω_1 和 ω_2
 - 先验概率: $P(\omega_1)$ 和 $P(\omega_2)$
 - 类条件概率密度函数: $p(x|\omega_1)$ 和 $p(x|\omega_2)$
 - 发生了一个随机事件, 其观察值为: 特征向量 x
 - 求最小错误率分类器

4. 2. 2 后验概率

- **Bayes**（条件概率）公式
 - $p(x|\omega_1) P(\omega_1) = p(x) P(\omega_1|x)$
 - $p(x|\omega_2) P(\omega_2) = p(x) P(\omega_2|x)$
- 后验概率
 - $P(\omega_1|x) = p(x|\omega_1) P(\omega_1) / p(x)$
 - $P(\omega_2|x) = p(x|\omega_2) P(\omega_2) / p(x)$
 - $p(X) = p(x|\omega_1) P(\omega_1) + p(x|\omega_2) P(\omega_2)$

4. 2. 3 决策规则

- 决策规则

- 比较后验概率，取最大值进行类别判断
- 对于未知样本 \mathbf{x} ，若 $P(\omega_1|\mathbf{x}) > P(\omega_2|\mathbf{x})$ ，则 $\mathbf{x} \in \omega_1$
- 若 $P(\omega_1|\mathbf{x}) < P(\omega_2|\mathbf{x})$ ，则 $\mathbf{x} \in \omega_2$

4. 2. 3 决策规则

- 等价规则一 后验概率分子
 - 比较分子 $p(x|\omega_1) P(\omega_1)$ 和 $p(x|\omega_2) P(\omega_2)$ ，取最大
 - 对于未知样本 x ，若 $p(x|\omega_1) P(\omega_1) > p(x|\omega_2) P(\omega_2)$ ，则 $x \in \omega_1$
 - 若 $p(x|\omega_1) P(\omega_1) < p(x|\omega_2) P(\omega_2)$ ，则 $x \in \omega_2$

4. 2. 3 决策规则

- 等价规则二 似然比

- 定义似然比函数 $l(x) = p(x|\omega_1) / p(x|\omega_2)$
- 对于未知样本 x , 若 $l(x) > P(\omega_2) / P(\omega_1)$, 则 $x \in \omega_1$
- 若 $l(x) < P(\omega_2) / P(\omega_1)$, 则 $x \in \omega_2$

4.2.3 决策规则

- 等价规则三 负对数似然比
 - 定义负对数似然比函数 $h(x) = -\ln l(x) = -\ln p(x|\omega_1) + \ln p(x|\omega_2)$
 - 对于未知样本 x , 若 $h(x) < \ln [P(\omega_1) / P(\omega_2)]$, 则 $x \in \omega_1$
 - 若 $h(x) > \ln [P(\omega_1) / P(\omega_2)]$, 则 $x \in \omega_2$

4.2.4 实例

- 已知

- 癌细胞图像识别：正常和异常两类（即 $C = 2$ ）
- 已知未知样本特征观察值： $x = 0.5$
- 又已知 $P(\omega_1) = 0.9$ 和 $P(\omega_2) = 0.1$
- 查函数曲线得 $p(0.5|\omega_1) = 0.2$ 和 $p(0.5|\omega_2) = 0.4$
（可以是先验或学习得到）
- 试对未知样本 $x = 0.5$ 进行分类

4.2.4 实例

- 已知

- 癌细胞图像识别：正常和异常两类（即 $C = 2$ ）
- 已知未知样本特征观察值： $x = 0.5$
- 又已知 $P(\omega_1) = 0.9$ 和 $P(\omega_2) = 0.1$
- 查函数曲线得 $p(0.5|\omega_1) = 0.2$ 和 $p(0.5|\omega_2) = 0.4$
- 试对未知样本 $x = 0.5$ 进行分类

解：利用贝叶斯公式，分别计算出 ω_1 及 ω_2 的后验概率。

$$P(\omega_1|x) = \frac{p(x|\omega_1)P(\omega_1)}{\sum_{j=1}^2 p(x|\omega_j)P(\omega_j)} = \frac{0.2 \times 0.9}{0.2 \times 0.9 + 0.4 \times 0.1} = 0.818$$
$$P(\omega_2|x) = 1 - p(\omega_1|x) = 0.182$$

根据贝叶斯决策规则式(2-2)，有

$$P(\omega_1|x) = 0.818 > P(\omega_2|x) = 0.182$$

所以合理的决策是把 x 归类于正常状态。

4.2.5 最小错误率的说明

- 最小错误率的说明（设 $C=2$, $D=1$ ）

- 错误率 $P(e)$ 的定义

首先应指出所谓错误率是指平均错误率,以 $P(e)$ 来表示,其定义为

$$P(e) = \int_{-\infty}^{\infty} P(e, \mathbf{x}) d\mathbf{x} = \int_{-\infty}^{\infty} P(e|\mathbf{x}) p(\mathbf{x}) d\mathbf{x} \quad (2-6)$$

其中 $\int_{-\infty}^{\infty} () d\mathbf{x}$ 表示在整个 d 维特征空间上的积分。

对两类别问题,从式(2-2)的决策规则可知,如果 $P(\omega_2|\mathbf{x}) > P(\omega_1|\mathbf{x})$,则决策应为 ω_2 。显然在作出决策 ω_2 时, \mathbf{x} 的条件错误概率为 $P(\omega_1|\mathbf{x})$;反之,则应为 $P(\omega_2|\mathbf{x})$ 。可表示为

$$P(e|\mathbf{x}) = \begin{cases} P(\omega_1|\mathbf{x}), & \text{当 } P(\omega_2|\mathbf{x}) > P(\omega_1|\mathbf{x}) \\ P(\omega_2|\mathbf{x}), & \text{当 } P(\omega_1|\mathbf{x}) > P(\omega_2|\mathbf{x}) \end{cases} \quad (2-7)$$

4.2.5 最小错误率的说明

- 最小错误率的说明（设**C=2**，**D=1**）

- 错误率**P(e)**的推导

- 做 ω_1 判别时的错误概率

$$P(e_{12}) = \int_{\mathfrak{R}_1} P(\omega_2 | x) p(x) dx = \int_{\mathfrak{R}_1} P(\omega_2) p(x | \omega_2) dx$$

- 做 ω_2 判别时的错误概率

$$P(e_{21}) = \int_{\mathfrak{R}_2} P(\omega_1 | x) p(x) dx = \int_{\mathfrak{R}_2} P(\omega_1) p(x | \omega_1) dx$$

- 总错误概率

$$P(e) = \int_{\mathfrak{R}_1} P(\omega_2) p(x | \omega_2) dx + \int_{\mathfrak{R}_2} P(\omega_1) p(x | \omega_1) dx$$

4.2.5 最小错误率的说明

- 最小错误率的说明（设**C=2**，**D=1**）

- 再假设t为唯一分界点（**C=2**，**D=1**）

- 做 ω_1 判别时的错误概率

$$P(e_{12}) = \int_{-\infty}^t P(\omega_2) p(x | \omega_2) dx$$


- 做 ω_2 判别时的错误概率

$$P(e_{21}) = \int_t^{\infty} P(\omega_1) p(x | \omega_1) dx$$

- 总错误概率

$$P(e) = \int_{-\infty}^t P(\omega_2) p(x | \omega_2) dx + \int_t^{\infty} P(\omega_1) p(x | \omega_1) dx$$

4.2.5 最小错误率的说明



$$P_1(e) = \int_{R_2} p(\mathbf{x}|\omega_1) d\mathbf{x}$$

$$P_2(e) = \int_{R_1} p(\mathbf{x}|\omega_2) d\mathbf{x}$$

4.2.5 最小错误率的说明

- 推广到多类（任意**C**类）
 - 已知条件和问题
 - **C**类**D**维问题： ω_1 , ω_2 , \dots , ω_C
 - 先验概率： $P(\omega_1)$, $P(\omega_2)$, \dots , $P(\omega_C)$
 - 类条件概率密度函数： $p(x | \omega_1)$, $p(x | \omega_2)$, \dots , $p(x | \omega_C)$
 - 发生了一个随机事件，其观察值为：特征向量 x
 - 求最小错误率分类器

4.2.5 最小错误率的说明

- 推广到多类（任意**C**类）
 - 判别函数
 - $P(\omega_i|x) = p(x|\omega_i) P(\omega_i) / p(x) \quad i = 1, \dots, C$
 - 决策规则
 - 对于未知样本 x ，若 $P(\omega_j|x) = \max P(\omega_i|x)$ ，则 $x \in \omega_j$

4.2.6 特点

- 最小错误率**Bayes**决策的特点
 - 已知条件多——各类概率分布
 - 最小错误率——概率意义上最优
 - 非线性分类器
 - 设计过程复杂

4.3 最小风险Bayes决策

- 4.3.1 问题的提出
- 4.3.2 决策规则
- 4.3.3 其它说明
- 4.3.4 特点

4.3.1 问题的提出

- 最小错误率**Bayes**决策
 - 最小错误率——概率意义上最优
 - 工程上是否最优？
- 错误分类的结果、代价或风险会是怎样的？
 - 考虑癌细胞图像识别的例子
- 出错的可能情况
 - 正常细胞 ω_1 错分为异常 ω_2
 - 异常细胞 ω_2 错分为正常 ω_1

4.3.1 问题的提出

- 区别状态和决策概念

- 状态：识别的目的是分类，把样本归类于其可能的自然状态（即类别）之一，将这种自然状态简称为状态，记为 ω
- 状态空间：所有可能的状态的集合构成状态空间，记为 Ω

4.3.1 问题的提出

- 区别状态和决策概念

- 决策：把样本归类于某个状态，或不能进行归类，都是决策，记为 α
- 决策空间：所有可能的决策（包括拒绝决策）的集合构成决策空间，记为A

4.3.1 问题的提出

- 已知条件（类别**C = 2**，决策**A = 2**）
 - ω_1 、 $P(\omega_1)$ 、 $p(x | \omega_1)$ 和 ω_2 、 $P(\omega_2)$ 、 $p(x | \omega_2)$
 - $\Omega = \{\omega_1, \omega_2\}$
 - $A = \{\alpha_1, \alpha_2\}$
 - 定义损失函数 $\lambda(\alpha_i, \omega_j)$ ，简记 λ_{ij}
 - 发生了一个随机事件，其观察值为特征向量 x
- 求最小风险分类器

4.3.2 决策规则

- 判别函数

- $P(\omega_j | x) = p(x | \omega_j) P(\omega_j) / p(x) \quad j = 1, 2$

- $R(\alpha_i | x) = E[\lambda(\alpha_i, \omega_j) | x] = \lambda_{i1} P(\omega_1 | x) + \lambda_{i2} P(\omega_2 | x) \quad i = 1, 2$

- 决策规则

- 对于未知样本 x ，若 $R(\alpha_k | x) = \min R(\alpha_i | x)$ ，则 $x \in \omega_k$ ，即决策 α_k

4.3.2 决策规则

- 推广到任意情况（**C**个类别，**A**个决策）
 - ω_j 、 $P(\omega_j)$ 、 $p(x|\omega_j)$ $j = 1, \dots, C$
 - $\Omega = \{\omega_1, \omega_2, \dots, \omega_C\}$
 - $A = \{\alpha_1, \alpha_2, \dots, \alpha_A\}$
 - 定义损失函数 $\lambda(\alpha_i, \omega_j)$ ，简记 λ_{ij}
 - 发生了一个随机事件，其观察值为特征向量 x
- 求最小风险分类器

4.3.2 决策规则

- 判别函数

- $P(\omega_j | x) = p(x | \omega_j) P(\omega_j) / p(x) \quad j = 1, 2, \dots, C$

- $R(\alpha_i, x) = E[\lambda(\alpha_i, \omega_j)] = \sum_{j=1} \lambda(\alpha_i, \omega_j) P(\omega_j | x) \quad i = 1, 2, \dots, A$

- 决策规则

- 对于未知样本 x ，若 $R(\alpha_k | x) = \min R(\alpha_i | x)$ ，则 $x \in \omega_k$ ，即决策 α_k

4.3.3 其它说明

- 最小风险与最小错误率的关系

- 0-1损失函数

$$\begin{aligned}\lambda(\alpha_i, \omega_j) &= 0 & i=j \\ \lambda(\alpha_i, \omega_j) &= 1 & i \neq j\end{aligned}$$

$$R(\alpha_i, x) = E[\lambda(\alpha_i, \omega_j)] = \sum_{j=1} \lambda(\alpha_i, \omega_j) P(\omega_j | x)$$

$$R(\alpha_i, x) = \sum_{\substack{j=1 \\ j \neq i}} P(\omega_j | x) = 1 - P(\omega_i | x)$$

4.3.3 其它说明

- 最小风险与最小错误率的关系

$$R(\alpha_i, x) = \sum_{\substack{j=1 \\ j \neq i}}^L P(\omega_j | x) = 1 - P(\omega_i | x)$$

- 对于未知样本 x ，若 $R(\alpha_k | x) = \min R(\alpha_i | x)$ ，则 $x \in \omega_k$
- 对于未知样本 x ，若 $P(\omega_k | x) = \max P(\omega_i | x)$ ，则 $x \in \omega_k$
- 结论：最小错误率**Bayes**决策，等价于**0-1**损失函数的最小风险**Bayes**决策

4.3.4 特点

- 最小风险**Bayes**决策的特点
 - 已知条件多——各类概率分布及风险系数
 - 最小错误风险——概率意义上最优
 - 非线性分类器
 - 设计过程复杂

例题

- 1、已知
 - 甲类: $P(\omega_1) = 0.7$ 和类条件概率密度函数 $p(x|\omega_1)$
 - 乙类: $P(\omega_2) = 0.3$ 和类条件概率密度函数 $p(x|\omega_2)$
 - 今有待分类样本特征观察值 $x = 10$, 且由函数曲线查得 $p(10|\omega_1) = 0.2$, $p(10|\omega_2) = 0.5$
 - (1)试用最小错误率Bayes决策对样本 $x = 10$ 进行分类
 - (2)试用最小风险Bayes决策对该样本进行分类, 设 $\lambda_{11}=\lambda_{22}=0$, $\lambda_{12}=2$, $\lambda_{21}=1$

4.4 最小最大决策

- 4.4.1 问题的提出
- 4.4.2 期望损失
- 4.4.3 最小最大风险
- 4.4.4 特点

4.4.1 问题的提出

- 已知条件和问题（**C = 2**情况）
 - 先验概率：考虑 $P(\omega_1)$ 和 $P(\omega_2)$ 未知或不确定的情况
 - 此时绝对意义的最小风险不存在
 - 如何求Bayes分类器
- 思路
 - 假设 $P(\omega_1)$ 和 $P(\omega_2)$ 确定
 - 设计系列最小风险Bayes分类器
 - 取其中最大风险为最小的一个来用
 - 目的是控制最大风险

4.4.1 问题的提出

- 问题（类别**C = 2**，决策**A = 2**）
 - ω_1 、 $p(x | \omega_1)$ 和 ω_2 、 $p(x | \omega_2)$
 - $\Omega = \{\omega_1, \omega_2\}$
 - $A = \{\alpha_1, \alpha_2\}$
 - 损失函数 $\lambda(\alpha_i, \omega_j)$ ，简记 λ_{ij}
 - 发生了一个随机事件，其观察值为特征向量 x
- 求最小最大风险分类器

4.4.2 期望损失

- 期望损失的推导（回顾最小错误率证明）

$$P(e) = \int_{\mathfrak{R}_1} P(\omega_2) p(x | \omega_2) dx + \int_{\mathfrak{R}_2} P(\omega_1) p(x | \omega_1) dx$$

$$P(e_{12}) = \int_{\mathfrak{R}_1} P(\omega_2) p(x | \omega_2) dx$$

$$P(e_{21}) = \int_{\mathfrak{R}_2} P(\omega_1) p(x | \omega_1) dx$$

4.4.2 期望损失

- 期望损失的推导

$$\begin{aligned} R &= \int R(a(x) | x) p(x) dx = \int_{\mathcal{X}_1} R(a_1 | x) p(x) dx + \int_{\mathcal{X}_2} R(a_2 | x) p(x) dx \\ &= \int_{\mathcal{X}_1} [\lambda_{11} P(\omega_1) p(x | \omega_1) + \lambda_{12} P(\omega_2) p(x | \omega_2)] dx + \int_{\mathcal{X}_2} [\lambda_{21} P(\omega_1) p(x | \omega_1) \\ &\quad + \lambda_{22} P(\omega_2) p(x | \omega_2)] dx \end{aligned}$$

$$P(\omega_2) = 1 - P(\omega_1)$$

$$\int_{\mathcal{X}_2} p(x | \omega_1) dx = 1 - \int_{\mathcal{X}_1} p(x | \omega_1) dx$$

4.4.2 期望损失

- 期望损失的推导

$$R = \lambda_{22} + (\lambda_{12} - \lambda_{21}) \int_{\mathcal{R}_1} p(\mathbf{x} | \omega_2) d\mathbf{x} + P(\omega_1) [(\lambda_{11} - \lambda_{22}) \\ + (\lambda_{21} - \lambda_{11}) \int_{\mathcal{R}_2} p(\mathbf{x} | \omega_1) d\mathbf{x} - (\lambda_{12} - \lambda_{22}) \int_{\mathcal{R}_1} p(\mathbf{x} | \omega_2) d\mathbf{x}]$$

$$a = \lambda_{22} + (\lambda_{12} - \lambda_{21}) \int_{\mathcal{R}_1} p(\mathbf{x} | \omega_2) d\mathbf{x}$$

$$b = (\lambda_{11} - \lambda_{22}) + (\lambda_{21} - \lambda_{11}) \int_{\mathcal{R}_2} p(\mathbf{x} | \omega_1) d\mathbf{x} - (\lambda_{12} - \lambda_{22}) \int_{\mathcal{R}_1} p(\mathbf{x} | \omega_2) d\mathbf{x}$$

推导思路：替换后改成只有 $P(\omega_2)$ 有关的形式

4.4.3 最小最大风险

- 最小最大风险的解

- 任给 $P(\omega_1)^*$ 的值, $P(\omega_2)^* = 1 - P(\omega_1)^*$
 - \downarrow
 - 求对应的最小风险Bayes分类器, 设决策域为 R_1 和 R_2
 - \downarrow
 - 计算对应的 a^* 和 b^* , 得到 $R^* = a^* - b^* P(\omega_1)^*$
 - \downarrow
 - 重复上述计算步骤, 得到一系列最小风险Bayes分类器, 并 可得 $P(\omega_1)^* \text{——} R^*$ 关系曲线
 - \downarrow
 - 比较所有最大风险, 取其中最小的一个, 作为最终的分类器

4.4.4 最小最大决策

- 最小最大决策的特点
 - 已知条件多——各类概率分布及风险系数
 - 最小最大风险——概率意义上最优
 - 非线性分类器
 - 设计过程很复杂

4.5 Bayes分类器设计

- 4.5.1 原理设计
- 4.5.2 Bayes决策面
- 4.5.3 错误率估计
- 4.5.4 其它

4.5.1 原理设计

- 两类情况（**C=2**）设计方法一

- 定义判别函数 $g(x)$

- ① $g(x) = P(\omega_1 | x) - P(\omega_2 | x)$

- ② $g(x) = p(x | \omega_1)P(\omega_1) - p(x | \omega_2)P(\omega_2)$

- ③ $g(x) = \ln \frac{p(x | \omega_1)}{p(x | \omega_2)} + \ln \frac{P(\omega_1)}{P(\omega_2)}$

- 决策面H方程

- $g(x) = 0$

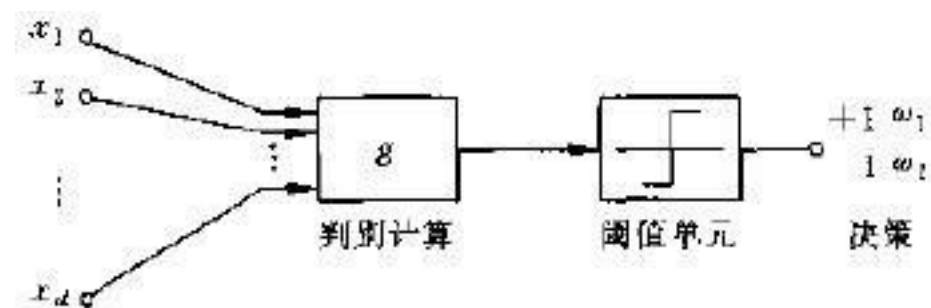
4.5.1 原理设计

- 两类情况 (**C=2**) 设计方法一

- 决策规则

- 对于未知样本 x , 若 $g(x) > 0$, 则 x 决策为 ω_1 类
- 若 $g(x) < 0$, 则 x 决策为 ω_2 类

- 原理图



4.5.1 原理设计

- 两类情况（**C=2**）设计方法二

- 定义判别函数 $g_1(x)$ 和 $g_2(x)$

- ① $g_i(x) = P(\omega_i | x)$

- ② $g_i(x) = p(x | \omega_i) P(\omega_i)$

- ③ $g_i(x) = \ln p(x | \omega_i) + \ln P(\omega_i)$

- 决策面H方程

- $g_1(x) = g_2(x)$

4.5.1 原理设计

- 两类情况（**C=2**）设计方法二
 - 决策规则
 - 对于未知样本 x ，若 $g_1(x) > g_2(x)$ ，则 x 决策为 ω_1 类
 - 若 $g_1(x) < g_2(x)$ ，则 x 决策为 ω_2 类
 - 原理图

4.5.1 原理设计

- 多类情况（**C**任意）设计方法
 - 定义判别函数 $g_i(\mathbf{x})$ $i = 1, 2, \dots, C$
 - ① $g_i(\mathbf{x}) = P(\omega_i | \mathbf{x})$
 - ② $g_i(\mathbf{x}) = p(\mathbf{x} | \omega_i) P(\omega_i)$
 - ③ $g_i(\mathbf{x}) = \ln p(\mathbf{x} | \omega_i) + \ln P(\omega_i)$
 - 决策面H方程
 - $g_i(\mathbf{x}) = g_j(\mathbf{x})$ $i, j = 1, 2, \dots, C$


4.5.1 原理设计

- 多类情况（**C**任意）设计方法

- 决策规则

- 对于未知样本 x ，若 $g_j(x) = \text{MAX } g_i(x)$ ，则 x 决策为 ω_j 类

- 原理图



4.5.2 正态分布决策面

- 单变量正态分布 / 一元正态分布

$$p(x) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left\{-\frac{1}{2}\left(\frac{x-\mu}{\sigma}\right)^2\right\}$$

4.5.2 正态分布决策面

- 多变量正态分布 / 多元正态分布

$$p(\mathbf{x}) = \frac{1}{(2\pi)^{d/2} |\Sigma|^{\frac{1}{2}}} \exp \left\{ -\frac{1}{2} (\mathbf{x} - \mu)^T \Sigma^{-1} (\mathbf{x} - \mu) \right\}$$

$$\mu = E\{\mathbf{x}\}$$

$$\Sigma = E\{(\mathbf{x} - \mu)(\mathbf{x} - \mu)^T\}$$



4.5.2 正态分布决策面

- 多元正态分布的性质

- 均值与方差
- 等概率密度点的轨迹

正态分布的等密度点的轨迹为超椭球面

$$(x - \mu)^T \Sigma^{-1} (x - \mu) = \text{常数}$$



$$\gamma^2 = (x - \mu)^T \Sigma^{-1} (x - \mu)$$

4.5.2 正态分布决策面

- 多元正态分布的性质

- 不相关性 & 独立性: 不相关性 = 独立性

$$\begin{aligned}\sigma_{ij}^2 &= E[(x_i - \mu_i)(x_j - \mu_j)], \quad i, j = 1, 2, \dots, d, i \neq j \\ &= E(x_i - \mu_i) \cdot E(x_j - \mu_j) \\ &= 0\end{aligned}$$

$$\Sigma = \begin{bmatrix} \sigma_{11}^2 & \cdots & 0 \\ \vdots & \ddots & \\ 0 & \cdots & \sigma_{dd}^2 \end{bmatrix}$$

$$\Sigma^{-1} = \begin{bmatrix} 1/\sigma_{11}^2 & \cdots & 0 \\ \vdots & \ddots & \vdots \\ 0 & \cdots & 1/\sigma_{dd}^2 \end{bmatrix}$$

4.5.2 正态分布决策面

- 多元正态分布的性质

- 边缘分布: 正态分布
- 条件分布: 正态分布
- 线性组合: 正态分布

4.5.2 正态分布决策面

- 正态分布时分类器的决策面方程

- 判别函数

③ $g_i(\mathbf{x}) = \ln p(\mathbf{x} | \omega_i) + \ln P(\omega_i)$

$$g_i(\mathbf{x}) = -\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu}_i)^T \boldsymbol{\Sigma}_i^{-1}(\mathbf{x} - \boldsymbol{\mu}_i) - \frac{d}{2} \ln 2\pi - \frac{1}{2} \ln |\boldsymbol{\Sigma}_i| + \ln P(\omega_i)$$

$$g_i(\mathbf{x}) = g_j(\mathbf{x})$$

$$-\frac{1}{2}[(\mathbf{x} - \boldsymbol{\mu}_i)^T \boldsymbol{\Sigma}_i^{-1}(\mathbf{x} - \boldsymbol{\mu}_i) - (\mathbf{x} - \boldsymbol{\mu}_j)^T \boldsymbol{\Sigma}_j^{-1}(\mathbf{x} - \boldsymbol{\mu}_j)] - \frac{1}{2} \ln \frac{|\boldsymbol{\Sigma}_i|}{|\boldsymbol{\Sigma}_j|} + \ln \frac{P(\omega_i)}{P(\omega_j)} = 0$$

- 决策面方程

4.5.2 正态分布决策面

- 正态分布时分类器的决策面方程

- 二次型判别函数

展开

$$\begin{aligned} g_i(\mathbf{x}) &= -\frac{1}{2}(\mathbf{x} - \mu_i)^T \Sigma_i^{-1}(\mathbf{x} - \mu_i) - \frac{1}{2} \ln |\Sigma_i| + \ln P(\omega_i) \\ &= \mathbf{x}^T W_i \mathbf{x} + w_i^T \mathbf{x} + w_{i0} \end{aligned}$$


$$W_i = -\frac{1}{2} \Sigma_i^{-1} \quad (d \times d \text{ 矩阵})$$

$$w_i = \Sigma_i^{-1} \mu_i \quad (d \text{ 维列向量})$$

$$w_{i0} = -\frac{1}{2} \mu_i^T \Sigma_i^{-1} \mu_i - \frac{1}{2} \ln |\Sigma_i| + \ln P(\omega_i)$$

4.5.2 正态分布决策面


- 决策面示例




(a) 圆

(b) 椭圆

(c) 抛物线



(d) 双曲线



(e) 直线

4.5.2 正态分布决策面

$$\begin{aligned} g_i(\mathbf{x}) &= -\frac{1}{2}(\mathbf{x}-\mu_i)^T \Sigma_i^{-1}(\mathbf{x}-\mu_i) - \frac{1}{2} \ln |\Sigma_i| + \ln P(\omega_i) \\ &= \mathbf{x}^T \mathbf{W}_i \mathbf{x} + \mathbf{w}_i^T \mathbf{x} + w_{i0} \end{aligned}$$

- 决策面特例一

- $\Sigma_i = \sigma^2 \mathbf{I} \quad i = 1, 2, \dots, C$

$$\Sigma_i = \begin{bmatrix} \sigma^2 & \dots & 0 \\ \vdots & \ddots & \vdots \\ 0 & \dots & \sigma^2 \end{bmatrix}$$

朴素贝叶斯
分类器

$$g_i(\mathbf{x}) = -\frac{1}{2\sigma^2}(\mathbf{x}-\mu_i)^T(\mathbf{x}-\mu_i) + \ln P(\omega_i)$$

准垂直平分

$$\mathbf{w}^T(\mathbf{x}-\mathbf{x}_0) = 0$$

$$\mathbf{w} = \mu_i - \mu_j$$

$$\mathbf{x}_0 = \frac{1}{2}(\mu_i + \mu_j) - \frac{\sigma^2}{\|\mu_i - \mu_j\|^2} \ln \frac{P(\omega_i)}{P(\omega_j)}(\mu_i - \mu_j)$$


4.5.2 正态分布决策面

- 决策面特例一

$$w^T(x - x_0) = 0$$

$$w = \mu_i - \mu_j$$

$$x_0 = \frac{1}{2}(\mu_i + \mu_j) - \frac{\sigma^2}{\|\mu_i - \mu_j\|^2} \ln \frac{P(\omega_i)}{P(\omega_j)} (\mu_i - \mu_j)$$



4.5.2 正态分布决策面

- 决策面特例二

- $\Sigma_i = \Sigma \quad i = 1, 2, \dots, C$

$$g_i(\mathbf{x}) = -\frac{1}{2}(\mathbf{x} - \mu_i)^T \Sigma^{-1}(\mathbf{x} - \mu_i) + \ln P(\omega_i)$$

$$\mathbf{w}^T(\mathbf{x} - \mathbf{x}_0) = 0$$

$$\mathbf{w} = \Sigma^{-1}(\mu_i - \mu_j)$$
$$\mathbf{x}_0 = \frac{1}{2}(\mu_i + \mu_j) - \frac{\ln \frac{P(\omega_i)}{P(\omega_j)}}{(\mu_i - \mu_j)^T \Sigma^{-1}(\mu_i - \mu_j)}(\mu_i - \mu_j)$$


4.5.2 正态分布决策面

- 决策面特例二

$$\mathbf{w}^T(\mathbf{x} - \mathbf{x}_0) = 0$$

$$\mathbf{w} = \Sigma^{-1}(\mu_i - \mu_j)$$

$$\mathbf{x}_0 = \frac{1}{2}(\mu_i + \mu_j) - \frac{\ln \frac{P(\omega_i)}{P(\omega_j)}}{(\mu_i - \mu_j)^T \Sigma^{-1}(\mu_i - \mu_j)}(\mu_i - \mu_j)$$



4.5.3 错误率估计

- **Bayes**分类器错误率的估计方法
 - 按理论公式求解计算*
 - 计算错误率上界
 - 实验估计错误率
- *注：直接计算十分困难，只能在特例情况下进行。

4.5.3 错误率估计

- 错误率的计算
 - 两类正态分布等协方差阵情况下

$$P(e) = \int_{\mathfrak{R}_1} P(\omega_2) p(x | \omega_2) dx + \int_{\mathfrak{R}_2} P(\omega_1) p(x | \omega_1) dx$$

$$P(e_{12}) = \int_{\mathfrak{R}_1} P(\omega_2) p(x | \omega_2) dx = P(\omega_2) \int_{\mathfrak{R}_1} p(x | \omega_2) dx = P(\omega_2) P_2(e)$$

$$P(e_{21}) = \int_{\mathfrak{R}_2} P(\omega_1) p(x | \omega_1) dx = P(\omega_1) \int_{\mathfrak{R}_2} p(x | \omega_1) dx = P(\omega_1) P_1(e)$$

4.5.3 错误率估计

- 错误率的计算

回顾最小错误率贝叶斯决策规则的负对数似然比形式。

$$h(\mathbf{x}) = -\ln l(\mathbf{x}) = -\ln p(\mathbf{x}|\omega_1) + \ln p(\mathbf{x}|\omega_2) \leq \ln \left[\frac{P(\omega_1)}{P(\omega_2)} \right] \rightarrow \mathbf{x} \in \begin{cases} \omega_1 \\ \omega_2 \end{cases}$$

$h(\mathbf{x})$ 是 \mathbf{x} 的函数, \mathbf{x} 是随机向量, 因此 $h(\mathbf{x})$ 是随机变量。我们记它的分布密度函数为 $p(h|\omega_1)$ 。由于它是一维密度函数, 因此易于积分, 所以用它计算错误率有时较为方便。这样式(2-113)可表示为

$$P_1(e) = \int_{\mathcal{X}_2} p(\mathbf{x}|\omega_1) d\mathbf{x} = \int_t^\infty p(h|\omega_1) dh \quad (2-114)$$

$$P_2(e) = \int_{\mathcal{X}_1} p(\mathbf{x}|\omega_2) d\mathbf{x} = \int_{-\infty}^t p(h|\omega_2) dh \quad (2-115)$$

$$\text{其中 } t = \ln[P(\omega_1) | P(\omega_2)] \quad (2-116)$$

4.5.3 错误率估计

$$p(\mathbf{x}) = \frac{1}{(2\pi)^{d/2} |\Sigma|^{1/2}} \exp \left\{ -\frac{1}{2} (\mathbf{x} - \mu)^T \Sigma^{-1} (\mathbf{x} - \mu) \right\}$$

$$\mu = E(\mathbf{x})$$

$$\Sigma = E\{(\mathbf{x} - \mu)(\mathbf{x} - \mu)^T\}$$

- 错误率的计算

$$h(\mathbf{x}) = -\ln l(\mathbf{x}) = -\ln p(\mathbf{x}|\omega_1) + \ln P(\mathbf{x}|\omega_2)$$

$$= - \left[-\frac{1}{2} (\mathbf{x} - \mu_1)^T \Sigma_1^{-1} (\mathbf{x} - \mu_1) - \frac{d}{2} \ln 2\pi - \frac{1}{2} \ln |\Sigma_1| \right]$$

$$+ \left[-\frac{1}{2} (\mathbf{x} - \mu_2)^T \Sigma_2^{-1} (\mathbf{x} - \mu_2) - \frac{d}{2} \ln 2\pi - \frac{1}{2} \ln |\Sigma_2| \right]$$

$$= \frac{1}{2} (\mathbf{x} - \mu_1)^T \Sigma_1^{-1} (\mathbf{x} - \mu_1) - \frac{1}{2} (\mathbf{x} - \mu_2)^T \Sigma_2^{-1} (\mathbf{x} - \mu_2) + \frac{1}{2} \ln \frac{|\Sigma_1|}{|\Sigma_2|}$$

$$\lesssim \ln \frac{P(\omega_1)}{P(\omega_2)} \rightarrow x \in \begin{cases} \omega_1 \\ \omega_2 \end{cases}$$

4.5.3 错误率估计

- 错误率的计算
 - 两类正态分布等协方差阵情况下

$$h(\mathbf{x}) = (\mu_2 - \mu_1)^T \Sigma^{-1} \mathbf{x} + \frac{1}{2} (\mu_1^T \Sigma^{-1} \mu_1 - \mu_2^T \Sigma^{-1} \mu_2)$$
$$\leq \ln \frac{P(\omega_1)}{P(\omega_2)} \rightarrow \mathbf{x} \in \begin{cases} \omega_1 \\ \omega_2 \end{cases}$$

4.5.3 错误率估计

$$h(\mathbf{x}) = (\mu_2 - \mu_1)^T \Sigma^{-1} \mathbf{x} + \frac{1}{2} (\mu_1^T \Sigma^{-1} \mu_1 - \mu_2^T \Sigma^{-1} \mu_2) \\ \leq \ln \frac{P(\omega_1)}{P(\omega_2)} \rightarrow \mathbf{x} \in \begin{cases} \omega_1 \\ \omega_2 \end{cases}$$

- 错误率的计算

- 线性组合仍然服从正态分布：通过均值和方差来估计错误率

$$\eta_1 = E[h(\mathbf{x}) | \omega_1] = (\mu_2 - \mu_1)^T \Sigma^{-1} \mu_1 + \frac{1}{2} (\mu_1^T \Sigma^{-1} \mu_1 - \mu_2^T \Sigma^{-1} \mu_2) \\ = -\frac{1}{2} (\mu_1 - \mu_2)^T \Sigma^{-1} (\mu_1 - \mu_2)$$

$$\eta = \frac{1}{2} [(\mu_1 - \mu_2)^T \Sigma^{-1} (\mu_1 - \mu_2)]$$

$$\eta_1 = -\eta$$

$$\sigma_1^2 = E\{[h(\mathbf{x}) - \eta]^2 | \omega_1\} = (\mu_1 - \mu_2)^T \Sigma^{-1} (\mu_1 - \mu_2) = 2\eta$$

$$\eta_2 = \frac{1}{2} (\mu_1 - \mu_2)^T \Sigma^{-1} (\mu_1 - \mu_2) = \eta$$

$$\sigma_2^2 = (\mu_1 - \mu_2)^T \Sigma^{-1} (\mu_1 - \mu_2) = 2\eta$$

4.5.3 错误率估计

- 错误率的计算
 - 线性组合仍然服从正态分布

$$\begin{aligned}P_1(e) &= \int_t^{\infty} p(h | \omega_1) dh \\&= \int_t^{\infty} \frac{1}{(2\pi)^{\frac{1}{2}} \sigma} \exp\left\{-\frac{1}{2}\left(\frac{h + \eta}{\sigma}\right)^2\right\} dh \\&= \int_t^{\infty} (2\pi)^{-\frac{1}{2}} \exp\left\{-\frac{1}{2}\left(\frac{h + \eta}{\sigma}\right)^2\right\} d\left(\frac{h + \eta}{\sigma}\right) \\&= \int_{\left(\frac{t + \eta}{\sigma}\right)}^{\infty} (2\pi)^{-\frac{1}{2}} \exp\left\{-\frac{1}{2}\xi^2\right\} d\xi\end{aligned}$$

4.5.3 错误率估计

- 错误率的计算
 - 线性组合仍然服从正态分布

$$\begin{aligned}P_2(e) &= \int_{-\infty}^t p(h|\omega_2)dh \\&= \int_{-\infty}^t (2\pi)^{-\frac{1}{2}} \exp\left\{-\frac{1}{2}\left(\frac{h-\eta}{\sigma}\right)^2\right\} d\left(\frac{h-\eta}{\sigma}\right) \\&= \int_{-\infty}^{\frac{t-\eta}{\sigma}} (2\pi)^{-\frac{1}{2}} \exp\left\{-\frac{1}{2}\xi^2\right\} d\xi\end{aligned}$$

$$t = \ln\left[\frac{P(\omega_1)}{P(\omega_2)}\right], \sigma = \sqrt{2\eta}$$

4.5.3 错误率上界

- 两类情况下最小错误率的上界

- Chernoff切尔诺夫上界

$$P(e_{12}) \leq P(\omega_2) e^{[-\mu(s) + (1-s)t]}$$

$$P(e_{21}) \leq P(\omega_1) e^{[-\mu(s) - st]}$$

- Bhattacharyya巴氏系数上界

$$J_B = -\ln \left[\int \sqrt{p(x | \omega_1) p(x | \omega_2)} dx \right]$$

$$P(e) \leq \sqrt{P(\omega_1) P(\omega_2)} \exp\{-J_B\}$$

4.5.3 错误率估计

- 错误率的实验估计
 - 测试样本集（区别于训练样本集）
 - 测试结果（有限样本情况，混淆矩阵）
 - 错误率评价

4.5.4 讨论

- **Bayes**决策的先决条件
 - 类条件概率密度的估计
 - 例：密度函数估计的简化
 - 假设特征向量各分量相互独立

4.5.4 讨论

- **Bayes**决策的最小错误概率
 - 设计难度大（类条件概率密度估计）
 - 寻求高“性价比”的分类器
 - 错误概率逼近
 - 决策面逼近

5 非线性分类器

- 5.1 多类问题概述
- 5.2 最小距离分类器
- 5.3 分段线性分类器概述
- 5.4 决策树
- 5.5 近邻法分类器
- 5.6 Adaboost
- 5.7 SVM
- 5.8 人工神经网络

5.1 多类问题概述

- 5.1.1 多类问题
- 5.1.2 解决方案

5.1.1 多类问题


- 多类问题包括
 - 两类情况 ($C = 2$)
 - 样本集具有多峰分布

5.1.1 多类问题概述

- 多类问题包括
 - 多类情况（类别数 $C > 2$ ）
 - 单峰分布
 - 多峰分布


5.1.2 解决方案

- 如何解多类问题
 - Bayes分类器
 - 二次型判别函数
 - 线性分类器
 - 其它分类器




5.1.2 解决方案

- 多类问题是否可以用线性分类器解？
 - 思路一
 - 对“类与类的非”进行线性分类
 - 只需要 $C - 1$ 个线性分类器就可以



5.1.2 解决方案

- 多类问题是否可以用线性分类器解？
 - 思路二
 - “两两分类”进行线性分类
 - 需要 $C(C-1)/2$ 个线性分类器就可以




5.2 最小距离分类器

- 5.2.1 最小距离分类器原理
- 5.2.2 分段最小距离分类器
- 5.2.3 特点

5.2.1 最小距离分类器原理

- 回顾两类单峰线性分类器
 - 垂直平分 / 最小距离分类器
 - 基于两类样本均值点作垂直平分线



5.2.1 最小距离分类器原理

- 其最小距离形式

- 判别函数


- $G_1(x) = d_1(x) = \|x - m_1\|$
 - $G_2(x) = d_2(x) = \|x - m_2\|$

- 决策规则


- 对于未知样本 x ，若 $d_1(x) < d_2(x)$ ，则 x 决策为 ω_1 类
 - 若 $d_1(x) > d_2(x)$ ，则 x 决策为 ω_2 类

5.2.1 最小距离分类器原理

- 直接使用可以解决多类问题
 - 解决C类单峰问题




(a) 三类



(b) 五类

5.2.1 最小距离分类器原理

- 直接使用可以解决多类问题
 - 解决两类多峰问题



5.2.2 分段最小距离分类器

- 问题

- 已知各类及其子类
- 求分段最小距离分类器

5.2.2 分段最小距离分类器

- 分类器设计

- 先求各子类均值

- m_{ij} (ω_i 类的第j子类)

- 定义各类判别函数

- $G_i(x) = \min_j \|x - m_{ij}\|$


- 决策规则

- 对于未知样本 x ，若 $G_k(x) = \min_i G_i(x)$ ，则 x 决策为 ω_k 类

5.2.3 特点

- 分类器特点

- 解决两类多峰或多类问题的分段线性分类器
- 可以解决几乎所有分类问题但要已知各类子类
- 概念直观简单，未经优化
- 分类器设计简单容易
- （无重叠区或空白区）



THE END !

